

Aprendizaje automático no supervisado

Guillermo Torralba Elipe

Tema 1

Introducción al aprendizaje no supervisado

Índice

- ¿Qué es el aprendizaje automático no supervisado?
- Ejemplos
- Términos clave
- Retos
- Flujo de trabajo
- Preprocesamiento

¿Qué es el aprendizaje automático no supervisado?

ENCUESTA

¿Qué es?

¿Conoces aplicaciones?

¿Qué es el aprendizaje automático no supervisado?


El UL (Unsupervised Machine Learning) se denomina así porque, a diferencia del supervisado, cuando se entrena el algoritmo, éste no conoce la etiqueta real.

Idea


Detección de patrones - estructuras - relaciones en los datos sin conocimiento previo.

Comparación: supervisado/no supervisado (clasificación)

Supervisado




No supervisado




Ejemplos de aplicaciones

Agrupamiento




Ejemplo: segmentación de clientes

Detección de anomalías




Ejemplo: identificación de fraudes

Reducción de la dimensionalidad



Ejemplo: mejorar la identificación en imágenes

Reglas de asociación



Ejemplo: distribución de los productos en la tienda

Términos clave

- **Características:** variables que se utilizan para el análisis. Definen las dimensiones del problema.
- **Dimensionalidad:** número de características.

Ejemplo:

Características o variables

Vehículos: n° ruedas, peso, vel. máx, n° pasajeros, n° de puertas
dim = 5

$$\vec{X}_1 = (2, 300, 250, 2, 0)$$

$$\vec{X}_2 = (4, 2.500, 160, 5, 5)$$

- **Grupo (cluster):** en el UML, corresponde a un conjunto de datos que comparten similitudes en base a algún criterio. Normalmente, alguna distancia.
- **Centroide:** centro de un grupo. Definido, también, en función de algún criterio.
- **Distancia:** función que expresa cuán próximos o separados están dos puntos.
- **Métrica:** función que cuantifica la calidad del resultado (no confundir con una métrica geométrica).

Ejemplo: distancia euclídea


$$i) d(x, y) \geq 0 ; d(x, y) = 0 \Leftrightarrow x = y$$

$$ii) d(x, z) \leq d(x, y) + d(y, z)$$

$$iii) d(x, y) = d(y, x)$$

- **Dato atípico/anomalía (outlier):** dato cuyo valor se desvía del comportamiento general.
- **Sobreajuste (overfitting):** se dice que un modelo sufre de sobreajuste cuando no es capaz de generalizar, esto es, cuando ajusta muy bien a los datos de entrenamiento pero es incapaz de ajustar o predecir correctamente datos con los que no ha sido entrenado.

Ejemplo: la línea verde presenta sobreajuste



- **Hiperparámetros:** parámetros de los que depende el algoritmo y que éste necesita para poder aplicarse. Son parámetros de entrada y que, una vez definidos, darán unos resultados u otros cuando se aplique sobre los datos.

Ejemplo: se quiere agrupar un conjunto de datos. ¿Cuántos grupos se van a formar? ¿Con qué criterio voy a decir que dos puntos pertenecen al mismo grupo?

2 grupos



3 grupos



Retos del aprendizaje no supervisado

- **"Maldición de la dimensionalidad" (*curse of dimensionality*):** conforme aumentan las dimensiones, el espacio se vuelve más grande y es más complicado encontrar patrones.
- **Interpretabilidad:** encontrar el significado de los resultados es tarea del analista.
- **Escalabilidad:** conforme aumenta el tamaño de los conjuntos de datos a analizar, es requisito que los algoritmos aplicados sean capaces de trabajar con ellos.
- **Número óptimo de grupos (para agrupamiento):** determinar el número de grupos que hay en un conjunto de datos puede ser subjetivo o, directamente, puede no ser de nuestro conocimiento.

- **Ruido:** una mejor o peor "calidad" de los datos puede conducir a resultados válidos o, por el contrario, poco informativos o, incluso, "falsos". En el UML, podría conducir a encontrar patrones que realmente no existen.
- **Métricas:** los resultados, al igual que con el aprendizaje supervisado, dependen de las métricas con las que los evaluamos.

-

Flujo "estándar" de trabajo

- Recolección de datos
- Limpieza y preprocesamiento de datos
- Preparación de los datos
- Elegir y aplicar un algoritmo no supervisado
- Entrenar y parametrizar el modelo
- Interpretación de los resultados
- Evaluación de los resultados

*En esta clase vamos a ver técnicas de limpieza y preprocesamiento. Pero, dentro de esta guía, añadir: **OBSERVAR LOS DATOS** ⇒ **SIEMPRE***

Limpieza y preprocesamiento

Las técnicas de preprocesado habituales son:

- Tratamiento de nulos
- Transformación de datos, estandarización/normalización/escalado
- Discretización
- Codificación de datos categóricos
- Tratamiento de valores atípicos (outliers)


Tratamiento de nulos

En ocasiones, se tendrán registros con datos "faltantes" o "nulos". Esto son registros en los que el valor de cierta(s) variables(s) no se tiene. Puede ser por un fallo al guardar los datos, un fallo al medirlos, un despiste, un olvido...

Muchas técnicas de ML no pueden trabajar con datos faltantes, con lo que un paso previo a aplicar cualquier técnica es ver qué hacer con ellos.


Eliminación

- Instancias/ejemplos: si no son muchos los ejemplos (filas, típicamente) que tienen algún valor nulo, se pueden eliminar.
- Variable: si una variable contiene excesivos ejemplos con nulos, se puede eliminar la variable (columna, típicamente).



Imputación cuando la variable es continua

Se pueden sustituir los valores faltantes por la media o la mediana. También se pueden utilizar otras técnicas como la regresión o kNN.



Imputación cuando la variable es categórica

Se pueden sustituir los valores faltantes por la moda. También se puede crear una nueva clase (normalmente, algo que haga referencia a que nos lo hemos inventado, como ‘Desconocido’).

A	B	C	D
Lunes	Naranja	0.67	1.13
Martes	Verde	-1.29	0.84
Lunes	NaN	-0.5	1.11
Sábado	Naranja	0.42	1.65

moda

A	B	C	D
Lunes	Naranja	0.67	1.13
Martes	Verde	-1.29	0.84
Lunes	Naranja	-0.5	1.11
Sábado	Naranja	0.42	1.65

nueva clase

A	B	C	D
Lunes	Naranja	0.67	1.13
Martes	Verde	-1.29	0.84
Lunes	Desconocido	-0.5	1.11
Sábado	Naranja	0.42	1.65



NOTA: un dato nulo no tiene por qué estar codificado como un NaN. Puede ser cualquier otro símbolo o número. Por ejemplo: -999 si se sabe que los datos son positivos, 0 si se sabe que no puede ser 0, una cadena vacía ""...

A	B	C	D
0.76	1.74	0.67	1.13
-0.43	-0.2	-1.29	0.84
-0.2	-999	-0.5	1.11
-0.08	-999	0.42	1.65



A	B	C	D
Lunes	Naranja	0.67	1.13
Martes	Verde	-1.29	0.84
Lunes		-0.5	1.11
Sábado	Naranja	0.42	1.65

Transformación de los datos

Para algunos algoritmos, especialmente los basados en la distancia, es bueno que las variables tengan rangos similares o que la distribución de los datos sea similar al de una distribución normal. También se pueden realizar transformaciones para que algunas relaciones no lineales entre las variables se vuelvan lineales.



Ejemplo: transformar relaciones no lineales en relaciones lineales



<https://archive.ics.uci.edu/dataset/477/real+estate+valuation+data+set>

- Escalado/normalización: hacer que los ejemplos o las variables tengan norma unidad.
- Estandarización: hacer que las variables tengan media nula y varianza unidad.

A	B	C	D	E
1.9756	0.4764	-6.5855	-1.6375	-7.5792
8.5231	9.5867	2.6659	3.8254	2.0594
9.5972	-9.2390	5.0108	-6.0007	-1.7394
8.7939	-9.6259	4.4746	-6.8256	-2.4224
1.0401	-1.4705	-8.4462	-0.6657	-3.7766
0.7282	-0.3429	-9.0871	-1.3965	-4.0294

$A \in [0.72, 1.97]$ Escalado
 $B \in [-9.62, 9.58]$
 $C = A_0 \in [0, 1], B_0 \in [0, 1] \rightarrow B_0 = \frac{B - B_{\min}}{B_{\max} - B_{\min}}$

normalización

• Estandarización: $A_{est} / E[A_{est}] = 0$
 $V[A_{est}] = 1$

$$\|\vec{x}_i\| = 1$$

$$A_{est} = \frac{A - E[A]}{\sigma(A)}$$

$\vec{x}_1 =$
 $\vec{x}_2 =$
 $\vdots$
 $\vec{x}_n$

A	B	C	D	E
0.190430	0.045919	-0.634795	-0.157843	-0.730581
0.617469	0.694525	0.193133	0.277139	0.149200
0.617435	-0.594387	0.322367	-0.386051	-0.111902
0.564746	-0.618176	0.287359	-0.438341	-0.155569
0.110075	-0.155621	-0.893850	-0.070450	-0.399669
0.072316	-0.034050	-0.902374	-0.138678	-0.400126

Discretización de datos continuos


Convertir variables continuas en discretas mediante agrupación en intervalos (bins). Puede resultar útil cuando el rango de los datos es amplio. Métodos de discretización son, entre otros, por intervalos iguales, por frecuencias iguales o usando conocimiento del tema.

Ejemplo: discretización de edades

Intervalos iguales

Número de intervalos: 10.

Anchura del intervalo: 7.3 años.




<https://archive.ics.uci.edu/dataset/20/census+income>

Frecuencias iguales

Número de intervalos: 10.

Anchura del intervalo: (5,4,4,3,4,4,4,5,8,32).

Age	Age_t_fixed	Age_t_q
39	3	5
50	4	8
58	5	9
...	...	...



Codificación de variables categóricas

La mayoría de las técnicas de ML requieren de datos numéricos para su aplicación.

Entre las más utilizadas están: *One Hot Encoding* y *Label Encoding*

- ***One Hot Encoding***: dada una característica cuyos valores son categorías, esta técnica crea nuevas características en base a las categorías originales, asignando 0 ó 1 en función del valor.
- ***Label Encoding***: asigna a cada categoría un valor numérico entero manteniendo una única característica.

Codificación de variables categóricas

Ejemplo: codificación del estado civil

Valores = {' Never-married', ' Married-civ-spouse', ' Divorced', ' Married-spouse-absent', 'Separated', ' Married-AF-spouse', ' Widowed'}

marital-status	Divorced	Married-AF-spouse	Married-civ-spouse	Married-spouse-absent	Never-married	Separated	Widowed	marital-status-encoded
Never-married	0.0	0.0	0.0	0.0	1.0	0.0	0.0	4
Married-civ-spouse	0.0	0.0	1.0	0.0	0.0	0.0	0.0	2
Divorced	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0
Married-civ-spouse	0.0	0.0	1.0	0.0	0.0	0.0	0.0	2
Married-civ-spouse	0.0	0.0	1.0	0.0	0.0	0.0	0.0	2
...	...	...	...	...	...	...	...	...
Married-civ-spouse	0.0	0.0	1.0	0.0	0.0	0.0	0.0	2
Married-civ-spouse	0.0	0.0	1.0	0.0	0.0	0.0	0.0	2
Widowed	0.0	0.0	0.0	0.0	0.0	0.0	1.0	6
Never-married	0.0	0.0	0.0	0.0	1.0	0.0	0.0	4
Married-civ-spouse	0.0	0.0	1.0	0.0	0.0	0.0	0.0	2

Original OneHotEncoder LabelEncoder

<https://archive.ics.uci.edu/dataset/20/census+income>

Tratamiento de valores atípicos (outliers)

En el conjunto de datos pueden existir valores que difieren del resto y perjudicar el análisis. Estas anomalías se entienden como algo que no es relevante o incluso a un error en la adquisición de datos. Cuando es así, hay que tratarlos.

Algunas de las técnicas usadas son:

- IQR (rango intercuartílico)
- Z-score

IQR

$$IQ = Q_3 - Q_1$$

$$x \notin [Q_1 - 1.5IQ, Q_3 + 1.5IQ] \rightarrow x_{out}$$


Z-score

$$Z = \frac{x - \mu}{\sigma}$$

$$P(X \in [\mu - \sigma, \mu + \sigma]) \approx 0.68$$

$$P(X \in [\mu - 2\sigma, \mu + 2\sigma]) \approx 0.95$$

$$P(X \in [\mu - 3\sigma, \mu + 3\sigma]) \approx 0.99$$



<https://archive.ics.uci.edu/dataset/20/census+income>



www.unir.net