

Aprendizaje automático no supervisado

Guillermo Torralba Elipe

Tema 2

Fundamentos y aplicaciones del agrupamiento K-Means

Índice

- Introducción
- Clustering: idea intuitiva
- Conceptos base
- KMeans
- KMeans: selección de K
- KMeans: ventajas y desventajas

Pregunta inicial I

¿En qué consiste el agrupamiento?

-

Pregunta inicial II

¿Cómo sabemos que el agrupamiento es correcto?

-


Ejemplos de agrupamiento

-

Introducción

- El agrupamiento es una de las piedras angulares del aprendizaje no supervisado.
- Consiste en agrupar datos de manera que los miembros de un mismo grupo sean similares entre sí y se diferencien de los miembros de otros grupos.
- A diferencia del aprendizaje supervisado, no se disponen de etiquetas previas que identifiquen los grupos.
- Los datos se agrupan debido a comportamientos o patrones similares.


Ejemplo: ¿Cómo podemos agrupar un conjunto de datos de clientes de una tienda en diferentes segmentos sin conocer previamente su comportamiento de compras?



Posibles perfiles:

- Jóvenes: con ingresos bajos y poca frecuencia de compra.
- Mediana edad: con ingresos medios y compras moderadas.
- Mayores: con altos ingresos y compras frecuentes

Clustering: idea intuitiva



- Queremos identificar qué datos son similares entre sí.
 - Los datos similares deben formar un grupo diferenciado.
- INPUT: características de los datos (ejemplo, características de los clientes)
- OUTPUT: grupo al que pertenece (ejemplo, cliente de mediana edad, con ingresos medios y compras moderadas).

Edad	Ingresos (USD)	Frecuencia de Compra (compras/mes)	Total Gastado (USD)
25	3000	2	500
40	7000	5	3000
35	4500	3	1200
28	3200	1	200
50	10000	7	8000

Conceptos base

Similitud: dos datos (vectores) son más o menos similares en base a una medida de la similitud. Existen distintas opciones para medir la similitud.

Recordatorio: distancia euclídea

$$d(x, y) = \sqrt{\sum_i (x_i - y_i)^2}$$

Propiedades:

- i) $d(x, y) \geq 0$ ($d(x, y) = 0 \iff x = y$)
- ii) $d(x, y) = d(y, x)$
- iii) $d(x, y) + d(y, z) \geq d(x, z)$

$$d_{12} = \left[(25 - 40)^2 + (3000 - 7000)^2 + (2 - 5)^2 + (500 - 3000)^2 \right]^{\frac{1}{2}} = \underline{\underline{4717'02}}$$

Cliente	Edad	Ingresos (USD)	Frecuencia de Compra (compras/mes)	Total Gastado (USD)
1	25	3000	2	500
2	40	7000	5	3000
3	35	4500	3	1200
4	28	3200	1	200
5	50	10000	7	8000

$$\tilde{d}_{12} = \sqrt{(3000 - 7000)^2 + (500 - 3000)^2} = 3.122'5$$

$$d_{34} = \sqrt{(35 - 28)^2 + (4500 - 3200)^2 + (3 - 1)^2 + (1200 - 200)^2} = \underline{\underline{1640'14}}$$

$$\tilde{d}_{34} = \sqrt{(4500 - 3200)^2 + (1200 - 200)^2} = 1.640'2$$

Matriz de distancias: matriz formada con las distancias de cada uno de los puntos a todos los demás.

$$M_{\text{dist}} = [M_{\text{dist}}]_{ij} = [d(x_i, x_j)] = \begin{pmatrix} d(x_1, x_1) & d(x_1, x_2) & \cdots & d(x_1, x_n) \\ d(x_2, x_1) & d(x_2, x_2) & \cdots & d(x_2, x_n) \\ \vdots & \vdots & \ddots & \vdots \\ d(x_n, x_1) & d(x_n, x_2) & \cdots & d(x_n, x_n) \end{pmatrix}$$


Centroide: "centro" del grupo

Promedio de las características de los miembros del grupo.

41

Cliente	Edad	Ingresos (USD)	Frecuencia de Compra (compras/mes)	Total Gastado (USD)
1	25	3000	2	500
2	40	7000	5	3000
4	28	3200	1	200

$$\mu_{c_1} = (31, 4,400, 2,67, 1233)$$



K-Means


Objetivo: asignar cada uno de los datos a uno de los k grupos definidos previamente.

Procedimiento (idea intuitiva):


1. Calcular las distancias de los datos a los centroides.
2. Asignar cada dato a su centroide más cercano.
3. Recalcular centroides
4. Repetir el proceso hasta que los centroides se estabilizan.

o se alcanza un número máximo de iteraciones.

Ejemplo: medidas de la graduación de alcohol y la intensidad del color de ciertos vinos.





(normalización)





iter: 0: [-0.18895962 -0.45028698], [0.61186923 1.45807213]

iter: 1: [-0.44116218 -0.58536249], [0.80529604 1.06851883]



iter: 2: [-0.58997276 -0.66209774], [0.81022926 0.90928089]



iter: 3: [-0.64965561 -0.68422335], [0.79582813 0.8381736]



iter: 9: [-0.87255162 -0.77936778], [0.71228703 0.63621859]

iter: 10: [-0.884056 -0.78672489], [0.70545883 0.62779057]

iter: 11: [-0.884056 -0.78672489], [0.70545883 0.62779057]



Procedimiento: dado un número k de grupos

1. Colocar los centroides en posiciones según algún criterio (por ejemplo, de forma aleatoria).
2. Calcular las distancias de los datos a los centroides.
3. Para cada dato:
 1. Obtener la distancia mínima entre sus distancias a los centroides.
 2. Asignar su etiqueta al del grupo con el centroide con distancia mínima.
4. Para cada grupo calcular su centroide.
5. Si la distancia entre los nuevos centroides y los anteriores son menores que cierta tolerancia, FIN, si no, volver al paso 2.



*o se alcanza un
número máximo de
iteraciones*

K-Means: selección del número de grupos. Hiperparámetros

¿Cuántos grupos (k) hay que elegir?

Recordemos que se quieren encontrar grupos lo más homogéneos posible y que difieran lo máximo entre ellos. Se necesitan medidas que expresen este objetivo.

Idealmente, existe cierto conocimiento a priori del número de grupos que puede haber en los datos.



Inercia

Mide la distancia intra-cluster, esto es, la distancia que separa cada uno de los puntos al grupo al que pertenecen.

$$I = \sum_{i=1}^N \|x_i - \mu_{c(i)}\|^2$$

- N es el número total de puntos en el conjunto de datos.
- x_i es el i -ésimo punto.
- $\mu_{c(i)}$ es el centroide del grupo al que pertenece el dato x_i
- $\|x_i - \mu_{c(i)}\|^2$ es la distancia euclídea al cuadrado entre los puntos x_i y $\mu_{c(i)}$

$$I = \sum_{i=1}^N \|x_i - \mu_{c(i)}\|^2$$



- Refleja la homogeneidad/heterogeneidad de los grupos.
- Mayor inercia, entonces, puntos más alejados de sus centros.
- También se conoce como *WCSS Within-Cluster-Sum of Squares*

Problema:

Cuanto mayor sea el número de grupos considerado, menor será la intercia. En el caso extremo de considerar tantos grupos como datos, la inercia se anula.

Técnica del codo

Se calculan las inercias para distintos valores de k y se toma como valor "óptimo" aquel en el que "se deja de ganar de manera significativa" al aumentar k .



Coeficiente de la silueta

Sea x_i un punto del conjunto de los datos.

Se definen:

$$a_i = \frac{1}{|C_i| - 1} \sum_{j \in \{C_j = C_i\}} d(x_i, x_j)$$

Distancia media del punto a los puntos que pertenecen al mismo grupo

$$b_i = \min \left[\frac{1}{|C_k|} \sum_{k \in \{C_k \neq C_i\}} d(x_i, x_j) \right]$$

Mínimo de las distancias medias del punto a los puntos de los otros grupos.

$$s_i = \frac{b_i - a_i}{\max [a_i, b_i]}$$

Silueta del punto.

Nótese que:

- i) $-1 \leq s_i \leq 1$
- ii) $s_i \approx -1 \rightarrow a_i \gg b_i$
- iii) $s_i \approx 1 \rightarrow a_i \ll b_i$



Punto mal asignado a su grupo

Punto bien asignado a su grupo

Ejemplo: sean los puntos $P_1(1,1)$, $P_2(1,2)$, $P_3(3,3)$, $P_4(5,5)$, $P_5(6,5)$. Calcular s_3 para los casos

a) $C_A = \{P_1, P_2, P_3\}$, $C_B = \{P_4, P_5\}$

b) $C_A = \{P_1, P_2\}$, $C_B = \{P_3, P_4, P_5\}$



a) $s_i = \frac{b_i - a_i}{\max[a_i, b_i]} \Rightarrow s_3 = \frac{b_3 - a_3}{\max[a_3, b_3]}$



$$a_i = \frac{1}{|C_i| - 1} \sum_{j \in \{C_j = C_i\}} d(x_i, x_j) \Rightarrow a_3 = \frac{1}{|C_3| - 1} \sum_{j \in \{C_j = C_3\}} d(P_3, P_j)$$

$$a_3 = \frac{1}{|C_A| - 1} [d(P_3, P_1) + d(P_3, P_2)] = \frac{1}{2} [\sqrt{8} + \sqrt{5}] = 2.53$$

$$b_i = \min \left[\frac{1}{|C_k|} \sum_{k \in \{C_k \neq C_i\}} d(x_i, x_j) \right] = \min \left[\frac{1}{|C_B|} (d(P_3, P_4) + d(P_3, P_5)) \right] =$$

$$= \frac{1}{2} [\sqrt{8} + \sqrt{13}] = 3.22$$

$$s_3 = \frac{3.21 - 2.53}{\max[2.53, 3.21]} = 0.21$$



b) Procediendo de la misma manera se puede llegar al resultado final:

$$\begin{array}{l} a_3 = 3.21 \\ b_3 = 2.53 \end{array} \rightarrow s_3 = \frac{2.53 - 3.21}{3.21} = -0.21$$




No está claro a qué grupo pertenece, sin embargo, su silueta es ligeramente superior cuando pertenece al grupo C_A

Para un valor de k (número de grupos) se calcula el valor medio de las siluetas.

$$s(k) = \frac{1}{N} \sum_i^N s_i$$

Se define el coeficiente de la silueta como el máximo de estos valores medios para distintos valores de k .

$$SC = \max_s [s(k)]$$



Estadística de brecha

Compara las inercias (distancias intra-cluster) de los datos (W_0) para un k dado con las inercias obtenidas para el mismo k con una distribución de datos supuestamente sin estructura (W_{ref}).




$$G(k) = E [\ln(W_{\text{ref}})] - \ln(W_0)$$

Se selecciona el k que satisfaga

$$G(k) \geq G(k + 1) + s_{k+1}$$

donde s_{k+1} es la desviación estándar de $G(k + 1)$

Estimating the Number of Clusters in a Data Set Via the Gap Statistic. Robert Tibshirani , Guenther Walther , Trevor Hastie. Journal of the Royal Statistical Society Series B: Statistical Methodology, Volume 63, Issue 2, July 2001, Pages 411–423, <https://doi.org/10.1111/1467-9868.00293>



K-Means: ventajas y desventajas

Ventajas

- Fácil de comprender e implementar
- Computacionalmente barato

Desventajas

- No clara elección del número de grupos.
- Puede quedar atrapado en mínimos locales.
- Sensible a los valores atípicos.
- Sólo válido para variables continuas.
- Puede que algún centroide quede aislado sin datos asignados.



www.unir.net