

# Aprendizaje automático no supervisado

Guillermo Torralba Elipe

Tema 3

Diferentes implementaciones de k-means

# Índice

- Recordatorio
- k-means de Lloyd (clásico)
- k-means de MacQueen
- k-means de Hartigan-Wong
- k-means de Elkan
- k-means++
- Soft k-Means / Fuzzy k-Means

# Debate

*¿Cuáles son las principales limitaciones de k-means?*

# Recordatorio

Dado un conjunto de datos, el agrupamiento pretende dividir el conjunto en grupos homogéneos que difieran entre ellos.

Uno de los algoritmos más simples que se pueden aplicar es el k-means. Este algoritmo minimiza la distancia de los datos de un grupo a su centroide.

Sin embargo, el número de grupos  $k$  es un parámetro que se debe establecer a priori.

# k-means de Lloyd (k-Means clásico)

## PROCEDIMIENTO

Dado  $k$  grupos:

Inicializar  $k$  centroides (aleatoriamente).

Mientras no se alcance la estabilidad\*:

    Asignar cada punto de datos al centroide más cercano.

    Recalcular los centroides

\*Criterio de estabilidad:

- La posición de los centroides ha variado menos que una cierta tolerancia respecto de la iteración anterior
- Se ha alcanzado el número máximo de iteraciones.

## VENTAJAS

- Bajo coste computacional comparado con otras implementaciones:  $O(nkdi)$   
 $n$  puntos de datos,  $k$  grupos,  $d$  dimensiones,  $i$  iteraciones

## DESVENTAJAS

- Sensibilidad a la inicialización de los centroides.
- Posibilidad de convergencia a mínimo local.
- Sensibilidad a valores atípicos.
- Posibilidad de centroides sin datos asignados.

# k-means de MacQueen

A diferencia del algoritmo de Lloyd, los centroides no se asignan inicialmente de manera aleatoria, sino que se asignan  $k$  puntos de datos como centroides (implementaciones actuales usan esta inicialización para Lloyd también).

El recálculo de los centroides se realiza cada vez que un dato se asigna a un centroide.

## PROCEDIMIENTO

Dado  $k$  grupos:

Inicializar de manera aleatoria  $k$  puntos de datos como centroides.

Mientras no se alcance la estabilidad:

    Para cada punto:

        Asignar el punto a un centroide.

        Recalcular los centroides

## **VENTAJAS**

- Mejora la asignación de los puntos a los grupos.
- Convergencia más rápida al recalcularse los centroides más veces.
- Más optimizado para un flujo de datos continuo.

## **DESVENTAJAS**

- Mayor coste computacional (a priori) para algunos casos.
- Sigue siendo sensible a la inicialización de los centroides.



# k-means de Hartigan-Wong

## PROCEDIMIENTO

Dado  $k$  grupos.

Seleccionar  $k$  puntos como centroides.

Asignar de manera aleatoria cada dato a un centroide.

Recalcular los centroides.

Mientras no se alcance la estabilidad:

Para cada punto  $x_i$ :

Para cada centroide  $c_j$ :

Calcular el coste global si el punto  $x_i$  perteneciese al centroide  $c_j$ .

Asignar  $x_i$  al centroide con menor coste.

Recalcular los centroides

## VENTAJAS/DESVENTAJAS

- Similares a las de MacQueen, aunque suele ser más rápido.
- Menos sensible a la inicialización de los grupos.
- Grupos más estables debido a la comparación punto a punto.

# k-means de Elkan


Esta implementación reduce el coste computacional.

Utiliza la desigualdad triangular.

*Desigualdad triangular*

Sean  $x, y, z$  tres puntos de un espacio métrico con distancia  $d$ , entonces:

$$d(x, z) \leq d(x, y) + d(y, z)$$



En base a esta desigualdad, Elkan propone que muchos de los cálculos de distancias hechos durante la aplicación de k-Means no son necesarios. En particular, sean los siguientes lemas:

### Lema 1

Intuición: si dos centroides están muy separados y un punto está cerca del suyo, no es necesario calcular la distancia al otro centroide

Sea  $x$  un punto de datos y sean  $c$  y  $c'$  dos centros. Entonces, si

$$d(c, c') \geq 2d(x, c) \Rightarrow d(x, c') \geq d(x, c)$$

### *Demostración*

Por la desigualdad triangular  $d(c, c') \leq d(c, x) + d(x, c') \rightarrow d(c, c') - d(x, c) \leq d(x, c')$

Como  $d(c, c') \geq 2d(x, c)$  entonces  $d(c, c') - d(x, c) \geq 2d(x, c) - d(x, c) = d(x, c)$

Comparando ambas expresiones:  $d(c, c') \geq d(x, c)$

### *Uso del Lema 1*

Sea  $x$  un punto y  $c$  el centroide al que está asignado. Sea  $c'$  otro centroide tal que  $d(c, c') \geq 2d(x, c)$ . Entonces,  $d(x, c') \geq d(x, c)$  y no es necesario calcular esta distancia.

Además, supongamos que conocemos una cota superior de  $d(x, c)$ :  $u(x) \geq d(x, c)$ . Entonces, sólo es necesario calcular

$$d(x, c') \text{ si } u(x) > \frac{1}{2}d(c, c')$$

## Lema 2

Sea  $x$  un punto de datos y sean  $c$  y  $c'$  dos centros. Entonces,

$$d(x, c') \geq \max [0, d(x, c) - d(c, c')]$$

### *Demostración*

Por la desigualdad triangular  $d(x, c) \leq d(x, c') + d(c, c') \rightarrow d(x, c') \geq d(x, c) - d(c, c')$

Además, por ser todas distancias, todas las cantidades son positivas.

### *Uso del Lema 2*

Sea  $x$  un dato. Sea  $c'$  un centroide en cierta iteración y sea  $c$  el mismo centroide en la siguiente iteración (supongamos que se identifican los centroides, por ejemplo, numerándolos).

Supongamos que se conoce una cota inferior  $l' \leq d(x, c')$

Entonces:

$$d(x, c) \geq \max [0, d(x, c') - d(c, c')] = \max [0, l' - d(c, c')] = l$$

De esta manera, se obtiene una cota inferior a la distancia del nuevo centro.

NOTA: es la única implementación (aquí descrita) donde se usa información de una iteración para la siguiente.

NOTA: los lemas mostrados se satisfacen para cualesquiera tres puntos de un espacio métrico con distancia definida.

## PROCEDIMIENTO

First, pick initial centers. Set the lower bound  $l(x, c) = 0$  for each point  $x$  and center  $c$ . Assign each  $x$  to its closest initial center  $c(x) = \operatorname{argmin}_c d(x, c)$ , using Lemma 1 to avoid redundant distance calculations. Each time  $d(x, c)$  is computed, set  $l(x, c) = d(x, c)$ . Assign upper bounds  $u(x) = \min_c d(x, c)$ .

Se evitan cálculos innecesarios  
de distancias

Next, repeat until convergence:

1. For all centers  $c$  and  $c'$ , compute  $d(c, c')$ . For all centers  $c$ , compute  $s(c) = \frac{1}{2} \min_{c' \neq c} d(c, c')$ .
2. Identify all points  $x$  such that  $u(x) \leq s(c(x))$ .
3. For all remaining points  $x$  and centers  $c$  such that
  - (i)  $c \neq c(x)$  and
  - (ii)  $u(x) > l(x, c)$  and
  - (iii)  $u(x) > \frac{1}{2}d(c(x), c)$ :
  - 3a. If  $r(x)$  then compute  $d(x, c(x))$  and assign  $r(x) = \text{false}$ . Otherwise,  $d(x, c(x)) = u(x)$ .
  - 3b. If  $d(x, c(x)) > l(x, c)$   
or  $d(x, c(x)) > \frac{1}{2}d(c(x), c)$  then  
    Compute  $d(x, c)$   
    If  $d(x, c) < d(x, c(x))$  then assign  $c(x) = c$ .
4. For each center  $c$ , let  $m(c)$  be the mean of the points assigned to  $c$ .
5. For each point  $x$  and center  $c$ , assign
$$l(x, c) = \max\{l(x, c) - d(c, m(c)), 0\}.$$
6. For each point  $x$ , assign
$$u(x) = u(x) + d(m(c(x)), c(x))$$
$$r(x) = \text{true}.$$
7. Replace each center  $c$  by  $m(c)$ .

Se evitan cálculos innecesarios  
de distancias



## **VENTAJAS**

- Al realizar menos cálculos de distancias se incrementa su eficiencia.
- Preferible en grandes conjuntos de datos (menos cálculos).

## **DESVENTAJAS**

- Más complicado de implementar.
- Sensible a los valores iniciales de los centroides.

# k-means++

Uno de los problemas recurrentes en las implementaciones de k-Means es la inicialización de los centroides. El k-Means++ mitiga esta desventaja.

## PROCEDIMIENTO

Dado  $k$  el número de grupos.

1. Seleccionar de manera aleatoria un dato como el primer centroide.
2. Mientras el número de centroides sea menor que  $k$ :
  - 2.1. Calcular las distancias de todos los datos a sus centroides más cercanos
  - 2.2. Elegir un nuevo centroide con probabilidad proporcional al cuadrado de estas distancias\*
3. Ejecutar k-Means

**\*Cálculo de la probabilidad de que un punto  $p$  sea un centroide:**

$$P(x_i) = \frac{d^2(x_i, c_i)}{\sum_j d^2(x_j, c_j)}$$

### **VENTAJAS**

- Se facilita la formación de grupos con centroides separados cubriendo todo el espacio.
- Aceleración de la convergencia.



### **DESVENTAJAS**

- Puede caer en mínimos locales.
- Inicialización más lenta y costosa.



## Ejemplo:

El primer centroide se selecciona de manera aleatoria y uniforme entre los puntos datos.

Al seleccionarlo, la probabilidad del siguiente centroide cambia.



...y, así, sucesivamente.



# Soft k-means / Fuzzy k-means

Con este algoritmo se permite que un dato pueda pertenecer a más de un grupo (grupos no muy bien definidos).

Cada uno de los datos, en lugar de estar asignado a un centroide (hard), tiene un valor de pertenencia "u" a cada centroide (soft), que se puede entender como una probabilidad (suman 1).

## PROCEDIMIENTO

Dado  $k$  el número de grupos y  $m > 1$  el parámetro de borrosidad (normalmente 2)

1. Inicializar la matriz de pertenencia  $U = [u_{ij}]$  (de manera aleatoria, basada en la distancia a los centroides...) de

manera que  $\sum_j u_{ij} = 1$

2. Mientras no se alcance la convergencia:

2.1. Recalcular los centroides:  $c_j = \frac{\sum_{i=1}^n u_{ij}^m \cdot x_i}{\sum_{i=1}^n u_{ij}^m}$

2. 2. Actualizar la matriz de pertenencia:  $u_{ij} = \frac{1}{\sum_{l=1}^k \left[ \frac{d(x_i, c_j)}{d(x_i, c_l)} \right]^{\frac{2}{m-1}}}$

**Ejemplo:** sea  $X$  la matriz de datos (3 puntos y 2 dimensiones) y  $c_1 = (1,0)$ ,  $c_2 = (0,2)$  los centroides. Sean  $k = 2$  y  $m = 2$ .

$$X = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 2 & 2 \end{pmatrix}$$

*Inicializar la matriz de pertenencia*

$$U = \begin{pmatrix} 0.5 & 0.5 \\ 0.6 & 0.4 \\ 0.4 & 0.6 \end{pmatrix}$$

(aleatoriamente)



Recalcular los centroides  $c_j = \frac{\sum_{i=1}^n u_{ij}^m \cdot x_i}{\sum_{i=1}^n u_{ij}^m}$

$$c_1 = \frac{u_{11}^2 \cdot x_1 + u_{21}^2 \cdot x_2 + u_{31}^2 \cdot x_3}{u_{11}^2 + u_{21}^2 + u_{31}^2} = \frac{(0.5)^2 \cdot (1,0) + (0.6)^2 \cdot (1,1) + (0.4)^2 \cdot (2,2)}{(0.5)^2 + (0.6)^2 + (0.4)^2} \approx (1.2, 0.88)$$

$$c_2 = \frac{u_{12}^2 \cdot x_1 + u_{22}^2 \cdot x_2 + u_{32}^2 \cdot x_3}{u_{12}^2 + u_{22}^2 + u_{32}^2} = \frac{(0.5)^2 \cdot (1,0) + (0.4)^2 \cdot (1,1) + (0.6)^2 \cdot (2,2)}{(0.5)^2 + (0.4)^2 + (0.6)^2} \approx (1.47, 1.14)$$

Actualizar la matriz de pertenencia (necesitamos conocer las distancias)

$$u_{ij} = \frac{1}{\sum_{l=1}^k \left[ \frac{d(x_i, c_j)}{d(x_i, c_l)} \right]^{\frac{2}{m-1}}}$$

$$d(x_1, c_1) = \sqrt{(x_{11} - c_{11})^2 + (x_{12} - c_{12})^2} = \sqrt{(1 - 1.2)^2 + (0 - 0.88)^2} = 0.92$$

$$d(x_1, c_2) = 1.23$$

$$d(x_2, c_1) = 0.23$$

$$d(x_2, c_2) = 0.49$$

$$d(x_3, c_1) = 1.38$$

$$d(x_3, c_2) = 1.01$$

$$u_{11} = \frac{1}{\left( \frac{d(x_1, c_1)}{d(x_1, c_1)} \right)^2 + \left( \frac{d(x_1, c_1)}{d(x_1, c_2)} \right)^2} = \frac{1}{1 + \left( \frac{0.92}{1.23} \right)^2} = 0.65$$

$$u_{12} = \frac{1}{\left( \frac{d(x_1, c_2)}{d(x_1, c_1)} \right)^2 + \left( \frac{d(x_1, c_2)}{d(x_1, c_2)} \right)^2} = \frac{1}{\left( \frac{1.23}{0.92} \right)^2 + 1} = 0.32$$

$$u_{21} = 0.82 \quad u_{22} = 0.18 \quad u_{31} = 0.35 \quad u_{32} = 0.65$$

## **VENTAJAS**

- Útil cuando la separación entre grupos no es clara.
- Más estabilidad frente a los valores atípicos ya que los valores atípicos no pesan tanto.

## **DESVENTAJAS**

- Computacionalmente más costoso.
- Necesidad de un hiperparámetro extra.



[www.unir.net](http://www.unir.net)

# Apéndice

Para el uso de variables categóricas, se puede investigar k-modes (categóricas) y k-prototypes (continuas y categóricas)