

Aprendizaje automático no supervisado

Guillermo Torralba Elipe

Tema 4

Agrupamiento jerárquico

Índice

- Agrupamiento jerárquico.
- Tipos de agrupamiento jerárquico.
- Medidas de enlace..
- Dendrograma.

Debate

¿Cuáles son las principales limitaciones de k-means?

Previa

Limitaciones de k-means:


- Requiere definir el número de grupos previamente.
- Asume que los grupos tienen forma esférica.

¿Qué ocurre si los datos tienen una estructura más rica?

Agrupamiento jerárquico

El agrupamiento jerárquico hace referencia a un agrupamiento en el que hay establecidas jerarquías a distintos niveles.

Ejemplo




Tipos de agrupamiento jerárquico

Dentro del agrupamiento jerárquico existen dos enfoques distintos: el aglomerativo y el divisivo.


Aglomerativo (bottom-up)

Cada dato comienza siendo su propio grupo. Posteriormente, se van uniendo los grupos en base a su similitud



Divisivo (top-down)

Todos los datos forman parte de un mismo grupo y se van dividiendo los grupos en base a su similitud.



Aglomerativo:

El más usado debido a su coste computacional. Además, es más sencillo de implementar.

- 1) Tengo imágenes de 1 dorada, 1 tiburón, 1 perro, 1 gato, 1 león, 1 gorila, 1 chimpancé, 1 ser humano, 1 gallo y 1 águila.
- 2) Tengo imágenes de 1 dorada, 1 tiburón, 1 perro, **2 felinos**, **3 primates**, 1 gallo y 1 águila.
- 3) Tengo imágenes de **2 peces**, **6 mamíferos** y **2 aves**.
- 4) Tengo imágenes de **10 animales**.

Divisivo:

- 1) Tengo imágenes de **10 animales**.
- 2) Tengo imágenes de **2 peces**, **6 mamíferos** y **2 aves**.
- 3) Tengo imágenes de 1 dorada, 1 tiburón, 1 perro, **2 felinos**, **3 primates**, 1 gallo y 1 águila.
- 4) Tengo imágenes de 1 dorada, 1 tiburón, 1 perro, 1 gato, 1 león, 1 gorila, 1 chimpancé, 1 ser humano, 1 gallo y 1 águila.

Medidas de similitud

La agrupación de los datos se hace en base a una medida de similitud, esto es, qué hace que dos puntos pertenezcan a un mismo grupo y qué hace que dos grupos sean distintos. Para ello, hay que definir una distancia (distancia entre puntos) y una manera de medir distancias entre grupos.

Distancias

Cualquier función que satisfaga las condiciones para ser una distancia (recordar Tema 2)


$$\begin{array}{ll} i) & d(x, y) \geq 0 \qquad (d(x, y) = 0 \iff x = y) \\ ii) & d(x, y) = d(y, x) \\ iii) & d(x, y) + d(y, z) \geq d(x, z) \end{array}$$

Enlaces


Los enlaces son las maneras que se tienen de medir distancias entre grupos.

Los más habituales son:


- **Distancia mínima (single-linkage):** distancia más corta entre dos puntos de distintos grupos. Puede manejar formas no elípticas pero es sensible a los valores atípicos.




- **Enlace completo:** mayor distancia entre dos puntos de distintos grupos. Menor sensibilidad a los valores atípicos.



- **Enlace promedio:** es el promedio de las distancias entre los puntos de los distintos grupos. Al igual que el enlace completo, es menos susceptible a los valores atípicos.



- **Distancia entre centroides:** se calcula la distancia entre los centroides de los grupos.





- **Método de la varianza mínima de Ward:** se utiliza en el agrupamiento aglomerativo. El método de Ward consiste en fusionar dos grupos en base a la optimización de una función objetivo. En particular, en este caso se minimiza la varianza. En cada paso, el par de grupos que se fusionan son aquellos cuyo incremento de la varianza total es menor. Este método, tiene una base estadística, sin embargo, sigue siendo sensible al ruido o valores atípicos. Además, es computacionalmente más costoso que los anteriores.


Dendrograma

Los dendrogramas son herramientas útiles para la visualización del agrupamiento jerárquico.


Es una figura en forma de árbol que representa la unión jerárquica de los grupos.



Para dibujar un dendrograma hay que proceder con el agrupamiento. Para ello se elige uno de los métodos con los que se dice que dos puntos son similares. En el eje X se colocan los puntos de datos y en el eje Y se muestra la distancia elegida. Se trazan líneas verticales hasta que dos grupos se encuentran a la distancia marcada por el eje Y, entonces, esos grupos se unen con una línea horizontal.




El dendrograma da una idea intuitiva y visual de cuántos grupos seleccionar. Permite elegir una distancia de corte trazando una línea horizontal a cierta altura, entonces, el número de líneas verticales cortadas por la línea horizontal es el número de grupos formados.



Ejemplo: sean los puntos A, B, C y D. Vamos a realizar el agrupamiento jerárquico aglomerativo, usando la distancia promedio entre grupos. Después, construiremos el dendrograma.

$$\begin{aligned} A &= (10, 5) \\ B &= (20, 20) \\ C &= (30, 10) \\ D &= (30, 15) \end{aligned}$$



Iteración 1

$$\begin{aligned} A &= (10, 5) \\ B &= (20, 20) \\ C &= (30, 10) \\ D &= (30, 15) \end{aligned}$$

Matriz de distancias (filas: A, B, C, D — columnas: A, B, C, D)


$$d(A, B) = \sqrt{(10 - 20)^2 + (5 - 20)^2} = \sqrt{100 + 225} = \sqrt{325} \approx 18.03$$

$$d(A, C) = \sqrt{(10 - 30)^2 + (5 - 10)^2} = \sqrt{400 + 25} = \sqrt{425} \approx 20.62$$

...

$$M_d^{(1)} \approx \begin{pmatrix} 0 & 18.03 & 20.62 & 22.36 \\ 18.03 & 0 & 14.14 & 11.18 \\ 20.62 & 14.14 & 0 & 5.00 \\ 22.36 & 11.18 & 5.00 & 0 \end{pmatrix}$$



$$\min [M_d^{(1)}] = 5 = d(C, D) \rightarrow \text{Se forma un nuevo grupo } \{C, D\}$$



Iteración 1

Al final de esta iteración se tienen los grupos $\{A\}$ $\{B\}$ $\{C, D\}$

$$\begin{aligned} A &= (10, 5) \\ B &= (20, 20) \\ C &= (30, 10) \\ D &= (30, 15) \end{aligned}$$



Iteración 2

$$\begin{aligned} A &= (10, 5) \\ B &= (20, 20) \\ C &= (30, 10) \\ D &= (30, 15) \end{aligned}$$

Matriz de distancias

La distancia promedio es, en este caso, el promedio de distancias:


$$d(A, \{C, D\}) = \frac{d(A, C) + d(A, D)}{2} \approx 21.5$$

$$d(B, \{C, D\}) = \frac{d(B, C) + d(B, D)}{2} \approx 12.67$$

$$M_d^{(2)} \approx \begin{pmatrix} 0 & 18.03 & 21.5 \\ 18.03 & 0 & 12.67 \\ 21.5 & 12.67 & 0 \end{pmatrix}$$

$$\min [M_d^{(2)}] = 12.67 = d(B, \{C, D\})$$



→ Se forma un nuevo grupo $\{B, C, D\}$



Iteración 2

Al final de esta iteración se tienen los grupos $\{A\}$ $\{B, C, D\}$

$$\begin{aligned} A &= (10, 5) \\ B &= (20, 20) \\ C &= (30, 10) \\ D &= (30, 15) \end{aligned}$$





Iteración 3

Finalmente, sólo queda unir el punto A que es a la distancia

$$d(A, \{B, C, D\}) = \frac{d(A, B) + d(A, C) + d(A, D)}{3} \approx 20.33$$

$$\begin{aligned} A &= (10, 5) \\ B &= (20, 20) \\ C &= (30, 10) \\ D &= (30, 15) \end{aligned}$$



Dibujar el dendrograma con código

```
A = (10, 5)
B = (20, 20)
C = (30, 10)
D = (30, 15)
```


```
model =
    AgglomerativeClustering(linkage="average",

                             distance_threshold=0,

                             n_clusters=None)
```

```
model.fit(X)
```

```
plot_dendro
```



Obtenido de https://scikit-learn.org/stable/auto_examples/cluster/plot_agglomerative_dendrogram.html

```
from scipy.cluster.hierarchy import dendrogram
from sklearn.cluster import AgglomerativeClustering

def plot_dendrogram(model, **kwargs):
    # Create linkage matrix and then plot the dendrogram

    # create the counts of samples under each node
    counts = np.zeros(model.children_.shape[0])
    n_samples = len(model.labels_)
    for i, merge in enumerate(model.children_):
        current_count = 0
        for child_idx in merge:
            if child_idx < n_samples:
                current_count += 1 # leaf node
            else:
                current_count += counts[child_idx - n_samples]
        counts[i] = current_count

    linkage_matrix = np.column_stack(
        [model.children_, model.distances_, counts]
    ).astype(float)

    # Plot the corresponding dendrogram
    dendrogram(linkage_matrix, **kwargs)
```

Programa de ejemplo

Tema4_ejemplo.ipynb



www.unir.net