

Aprendizaje automático no supervisado

Guillermo Torralba Elipe

Tema 5

Clustering basado en densidad DBSCAN

Índice

- Introducción
- Tipos de agrupamiento
- Algoritmos basados en densidad
- DBSCAN

Debate


¿Cuáles son las diferencias entre k-means y el agrupamiento jerárquico?

¿Cuáles son sus limitaciones?

Introducción


- Hasta ahora hemos visto técnicas de agrupamiento que funcionan bien con grupos esféricos (más para k-Means y menos para el jerárquico).
- Ambos métodos se ven afectados por la presencia de ruido y/o valores atípicos.
- DBSCAN es una técnica de agrupamiento basada en la densidad, distinto de los vistos hasta ahora (basados en la distancia)
- DBSCAN no necesita conocer previamente el número de grupos, no necesita conjuntos convexos ni esféricos y, además, es menos sensible al ruido (incluso puede identificarlo).

Tipos de agrupamiento



Ghosal, A., Nandy, A., Das, A.K., Goswami, S., & Panday, M. (2019). A Short Review on Different Clustering Techniques and Their Applications. Advances in Intelligent Systems and Computing.

Basados en particiones



El conjunto de datos se divide en grupos.

Todos los datos deben pertenecer a algún grupo.

Se necesita conocer el número de grupos previamente.

Minimización de una función de pérdida que depende de la distancia a un centroide.

Jerárquico




Dos tipos de enfoques: top-down y bottom-up.

No se necesita conocer el número de grupos de antemano.

El número de grupos se obtiene después mediante el uso de un dendrograma.

Basados en densidad (*)



Identifican regiones de densidades distintas.


Las regiones de alta densidad se caracterizan como grupos mientras que las de baja densidad se usan como "barreras" para hacer la partición del espacio.

Para determinar lo que significa alta densidad utilizan un "radio de vecindad".

No se necesita conocer el número de grupos de antemano.

(*) Hoy veremos este tipo de técnicas

Basados en mallas




En lugar de agrupar los datos, estos métodos definen una malla que divide el espacio en celdas.

Los datos se colocan en las celdas y si estas celdas satisfacen ciertas condiciones (densidad) se considera que la celda o celdas forman un grupo.

Computacionalmente eficiente.



Basados en modelos



Se asume que los datos están distribuidos en grupos que siguen ciertas distribuciones de probabilidad (por ejemplo, gaussianas), generalmente, un modelo de mezcla.

Los parámetros de los modelos se infieren usando distintas técnicas estadísticas (por ejemplo, máxima verosimilitud o BIC)

Algoritmos basados en densidad



El objetivo es encontrar agrupaciones asumiendo que las densidades de los datos difieren de un grupo a otro y que los grupos definen regiones de alta densidad.

- No requiere conocer el número de grupos previamente.
- Manejan valores atípicos o ruido en los datos.
- No requiere que las estructuras sean esféricas/elípticas


Uno de los algoritmos basados en densidad es DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

¿Por qué agrupamiento basado en densidad?


¿Y si los datos tienen ruido?




K-Means




DBSCAN




¿Y si, además, los grupos ni siquiera tienen una estructura esférica/elíptica?



K-Means



DBSCAN



DBSCAN

Para comprender el algoritmo DBSCAN hay que definir algunos parámetros fundamentales del método.


DEFINICIONES

Sean D un conjunto de datos, d la distancia, $\varepsilon \in \mathbb{R}_+$ y $\text{minPts} \in \mathbb{N}$

- **Vecindad de radio ε de un punto**

Dado un punto, la vecindad de radio ε viene dada por aquellos puntos que se encuentran a una distancia igual o inferior a ε


$$N_\varepsilon(p) = \{q \in D : d(p, q) \leq \varepsilon\}$$



- **Puntos densamente alcanzables de forma directa**

Un punto p es densamente alcanzable de forma directa por un punto q si:

- $p \in N_\varepsilon(q)$; p está en la vecindad ε de q
- $|N_\varepsilon(q)| \geq \text{minPts}$; la vecindad de q tiene igual o más puntos que un valor minPts




Si $\text{minPts} = 4$ p es densamente alcanzable de forma directa por q pero q no es alcanzable de forma directa por p

- **Punto densamente alcanzable**

Un punto p es densamente alcanzable desde q si existe una sucesión de puntos

$\{q=p_1, p_2, p_3, \dots, p_n=p\}$ tales que p_{i+1} es directamente alcanzable desde p_i .




Sea $\text{minPts} = 4$. Entonces:

- $s \in N_\epsilon(p)$ y $|N_\epsilon(p)| \geq \text{minPts} \rightarrow s$ es directamente alcanzable por p .
- $q \in N_\epsilon(s)$ y $|N_\epsilon(q)| \geq \text{minPts} \rightarrow q$ es directamente alcanzable por s .

- **Puntos densamente conectados**

p y q están densamente conectados si existe un punto s tal que tanto p como q son densamente alcanzables desde s .



p y q están densamente conectados

- **Grupo**

Un grupo C es un subconjunto no vacío de los datos que satisface:

- Si p pertenece al grupo C y q es densamente alcanzable desde p , entonces q pertenece al grupo C .
- Si p y q pertenecen al grupo C , p está densamente conectado con q .

- **Ruido**

Todos los puntos del conjunto de datos que no forman parte de ningún grupo.

Con este procedimiento, DBSCAN clasifica los puntos pertenecientes a un grupo como:

- **Puntos centrales**


Puntos que tienen un número mayor o igual a minPts en su vecindario ϵ

- **Puntos fronterizos**

Puntos que no son centrales pero están dentro del vecindario de, al menos, un punto central

- **Ruido**

Puntos que no son centrales ni fronterizos



<https://www.kdnuggets.com/2020/04/dbscan-clustering-algorithm-machine-learning.html>

De las definiciones anteriores se deducen los siguientes lemas:

1. Sea $p \in D$ tal que $|N_\epsilon(p)| \geq \text{minPts}$. Entonces, el conjunto de puntos densamente alcanzables desde p forman un grupo.
2. Sea $C \subset D$ y sea p un punto central, $p \in C$ tal que $|N_\epsilon(p)| \geq \text{minPts}$, entonces, todos los puntos densamente alcanzables por p pertenecen a C

PROCEDIMIENTO

Dados minPts y ε

$C = 0$

Para cada p no visitado

 Marcar p como visitado

 Construir $N_\varepsilon(p)$ (vecindad)

 Si $|N_\varepsilon(p)| < \text{minPts} \rightarrow$ marcar p como ruido

 Si no

$C = C + 1$

 ExtenderGrupo($p, N_\varepsilon(p), C$)

ExtenderGrupo($p, N_\varepsilon(p), C$)

 Añadir p al grupo C

 Para cada p' de la vecindad

 Si p' no se ha visitado

 Marcar p' como visitado

 Construir $N_\varepsilon(p')$

 Si $|N_\varepsilon(p')| \geq \text{minPts}$

$N_\varepsilon(p) \leftarrow N_\varepsilon(p) \cup N_\varepsilon(p')$

 Si p' no pertenece a ningún grupo

$C \leftarrow C \cup p'$

Ejemplo:

Seleccionamos $\varepsilon = 1.5$; minPts = 2

Sean los puntos de datos

$$A = (1, 1)$$

$$B = (2, 1)$$


$$C = (1, 3)$$

$$D = (2, 2)$$

$$E = (5, 5)$$


$$F = (4, 5)$$

$$G = (10, 10)$$



Calculamos la matriz de distancias

$A = (1, 1)$
 $B = (2, 1)$
 $C = (1, 3)$
 $D = (2, 2)$
 $E = (5, 5)$
 $F = (4, 5)$
 $G = (10, 10)$




$$M_d = \begin{pmatrix} 0 & 1 & 2 & 1.41 & 5.66 & 5 & 12.73 \\ 1 & 0 & 2.24 & 1 & 5 & 4.47 & 12.04 \\ 2 & 2.24 & 0 & 1.41 & 4.47 & 3.61 & 11.4 \\ 1.41 & 1 & 1.41 & 0 & 4.24 & 3.61 & 11.31 \\ 5.66 & 5 & 4.47 & 4.24 & 0 & 1 & 7.07 \\ 5 & 4.47 & 3.61 & 3.61 & 1 & 0 & 7.81 \\ 12.73 & 12.04 & 11.4 & 11.31 & 7.07 & 7.81 & 0 \end{pmatrix}$$

$A = (1, 1)$
 $B = (2, 1)$
 $C = (1, 3)$
 $D = (2, 2)$
 $E = (5, 5)$
 $F = (4, 5)$
 $G = (10, 10)$

$\varepsilon = 1.5; \text{minPts} = 2$

$$M_d = \begin{pmatrix} 0 & 1 & 2 & 1.41 & 5.66 & 5 & 12.73 \\ 1 & 0 & 2.24 & 1 & 5 & 4.47 & 12.04 \\ 2 & 2.24 & 0 & 1.41 & 4.47 & 3.61 & 11.4 \\ 1.41 & 1 & 1.41 & 0 & 4.24 & 3.61 & 11.31 \\ 5.66 & 5 & 4.47 & 4.24 & 0 & 1 & 7.07 \\ 5 & 4.47 & 3.61 & 3.61 & 1 & 0 & 7.81 \\ 12.73 & 12.04 & 11.4 & 11.31 & 7.07 & 7.81 & 0 \end{pmatrix}$$



Iteración 1

$V = \{A\}$ (visitados)

$N_\varepsilon(A) = \{B, D\} \rightarrow |N_\varepsilon(A)| = 2 \geq \text{minPts} \Rightarrow \text{Extender}(A, N_\varepsilon(A), G_1)$

Extensión:

$G_1 = \{A\}$

- Empezamos visitando $B \rightarrow V = \{A, B\}$

$N_\varepsilon(B) = \{A, D\} \rightarrow |N_\varepsilon(B)| = 2 \geq \text{minPts} \Rightarrow N_\varepsilon(A) = N_\varepsilon(A) \cap N_\varepsilon(B) = \{A, B, D\}$

Como B no pertenece a ningún grupo, entonces $G_1 = \{A, B\}$

- Visitamos $D \rightarrow V = \{A, B, D\}$

$N_\varepsilon(D) = \{A, B, C\} \rightarrow |N_\varepsilon(D)| = 3 \geq \text{minPts} \Rightarrow$

$N_\varepsilon(A) = N_\varepsilon(A) \cap N_\varepsilon(D) = \{A, B, C, D\}$. Como D no pertenece a ningún grupo, entonces $G_1 = \{A, B, D\}$.


- Visitamos $C \rightarrow V = \{A, B, C, D\}$.

$N_\varepsilon(C) = \{D\} \rightarrow |N_\varepsilon(C)| = 1 < \text{minPts}$. Como C no pertenece a ningún grupo, entonces $G_1 = \{A, B, C, D\}$

$A = (1, 1)$
 $B = (2, 1)$
 $C = (1, 3)$
 $D = (2, 2)$
 $E = (5, 5)$
 $F = (4, 5)$
 $G = (10, 10)$

$\varepsilon = 1.5; \text{minPts} = 2$

$$M_d = \begin{pmatrix} 0 & 1 & 2 & 1.41 & 5.66 & 5 & 12.73 \\ 1 & 0 & 2.24 & 1 & 5 & 4.47 & 12.04 \\ 2 & 2.24 & 0 & 1.41 & 4.47 & 3.61 & 11.4 \\ 1.41 & 1 & 1.41 & 0 & 4.24 & 3.61 & 11.31 \\ 5.66 & 5 & 4.47 & 4.24 & 0 & 1 & 7.07 \\ 5 & 4.47 & 3.61 & 3.61 & 1 & 0 & 7.81 \\ 12.73 & 12.04 & 11.4 & 11.31 & 7.07 & 7.81 & 0 \end{pmatrix}$$



Iteración 2

$V = \{A, B, C, D, E\}$ (vistamos un nuevo punto no visitado, E)

$N_\varepsilon(E) = \{F\} \rightarrow |N_\varepsilon(E)| = 1 < \text{minPts} \Rightarrow \text{Ruido}$

Iteración 3

$V = \{A, B, C, D, E, F\}$ (vistamos un nuevo punto no visitado, F)

$N_\varepsilon(F) = \{E\} \rightarrow |N_\varepsilon(F)| = 1 < \text{minPts} \Rightarrow \text{Ruido}$

Iteración 4

$V = \{A, B, C, D, E, F, G\}$ (vistamos un nuevo punto no visitado, G)

$N_\varepsilon(G) = \emptyset \rightarrow |N_\varepsilon(G)| = 0 < \text{minPts} \Rightarrow \text{Ruido}$

Clasificación final


Se tiene un grupo $G_1 = \{A, B, C, D\}$

Como $\minPts \leq N_\epsilon(A), N_\epsilon(B), N_\epsilon(D)$, los puntos A, B y D son puntos centrales.

Como C pertenece a un grupo pero no es central, es fronterizo.

Los puntos E, F y G son ruido

$$\begin{aligned} A &= (1, 1) \\ B &= (2, 1) \\ C &= (1, 3) \\ D &= (2, 2) \\ E &= (5, 5) \\ F &= (4, 5) \\ G &= (10, 10) \end{aligned}$$



Aviso: en *scikit-learn*, el parámetro no es *minPts* sino *min_samples*, esto incluyen los puntos centrales, por tanto, corresponde a *minPts+1* en los cálculos realizados aquí.



www.unir.net