

Aprendizaje automático no supervisado

Guillermo Torralba Elipe

Tema 6

Técnicas lineales. Análisis de componentes principales (PCA)

Índice

- Introducción
- Enfoques para la reducción de dimensionalidad
- Análisis de componentes principales (PCA)
- Varianzas de las variables proyectadas
- Selección del número de componentes principales
- Comprensión de las componentes principales
- Ventajas/desventajas de PCA

Previa

Ahora entramos en un nuevo bloque de la asignatura, la reducción de la dimensionalidad.

- Tema 1: Introducción
- Tema 2: Fundamentos y aplicaciones del agrupamiento K-Means
- Tema 3: Diferentes implementaciones de K-Means
- Tema 4: Agrupamiento jerárquico
- Tema 5: Clustering basado en densidad DBSCAN
- Tema 6: Técnicas lineales. Análisis de componentes principales (PCA)
- Tema 7: Técnicas no lineales. t-SNE, MDS e ISOMAP
- Tema 8: Detección de anomalías
- Tema 9: Introducción al aprendizaje por refuerzo
- Tema 10: Q-learning

Agrupamiento

Reducción de la
dimensionalidad

Anomalías

RL

¿Se pueden tener variables redundantes en los datos?

- Un ejemplo de variables redundantes en los datos podrían ser los ingresos promedios semanales frente a los mensuales en una empresa, ya que ambas dan la misma información siendo la diferencia entre ellas un factor multiplicativo (el número de semanas que tiene un mes).
- En una escudería de Fórmula 1, en el conjunto {velocidad promedio, distancia, tiempo} una de las tres variables es redundante, ya que $\text{velocidad promedio} = \text{distancia} / \text{tiempo}$.

¿Cuál es la diferencia entre selección de características y extracción de características?

Introducción

- La reducción de dimensionalidad busca simplificar conjuntos de datos complejos sin perder información relevante.
- En problemas reales, los datos pueden contener cientos o miles de variables, entre las que puede haber variables redundantes o, incluso, irrelevantes.
- El exceso de dimensiones puede ocasionar:
 - Dificultad para interpretar/visualizar el análisis
 - Aumento del coste computacional
 - Dificultad para conseguir un buen rendimiento del modelo.
- Mediante la reducción de dimensionalidad se pretende representar el espacio original en otro con menos dimensiones que contenga la información original relevante y que mitigue las dificultades encontradas cuando la dimensión de los datos es excesiva.

Enfoques para la reducción de dimensionalidad

Entre los enfoques que se pueden aplicar para reducir las dimensiones se encuentran principalmente dos:

- Selección de características
- Extracción de características


SELECCIÓN DE CARACTERÍSTICAS

La selección de características es la eliminación de ciertas características dejando las otras sin modificar.

EXTRACCIÓN DE CARACTERÍSTICAS

La extracción de características es el proceso de combinar o transformar variables ya existentes para crear otras nuevas.

Ejemplo: predicción de lesiones en jugadores para la próxima temporada



Análisis de componentes principales (PCA)

¿Qué hace que una variable sea relevante para describir los datos?

Una característica importante puede ser su variabilidad.


En PCA se asume, de hecho, que es lo más relevante.

Matemáticamente, una medida de la variación de una variable X es su varianza:


$$V[X] = (X - E[X])^2 = E[X^2] - (E[X])^2$$

donde $E[X]$ es el valor esperado.

En PCA nos preguntamos cuáles son las proyecciones que puedo hacer en los datos para maximizar la variación de las variables aleatorias.



La proyección sobre la primera dirección (imagen de la izquierda) tiene una menor varianza que la proyección sobre la segunda (imagen de la derecha)



Encontrar la proyección buscada es sólo un problema de maximización. En este caso, maximización de la varianza.

PROYECCIÓN EN UNA DIMENSIÓN

Sean

$$X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1d} \\ x_{21} & x_{22} & \dots & x_{2d} \\ \vdots & \vdots & \dots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nd} \end{pmatrix} \in \mathbb{R}^{n \times d}$$


Matriz de n datos de dimensión d

$\vec{v}$

Vector en la dirección de la proyección
(lo que se busca)

Dados dos vectores $\vec{a}$ y $\vec{b}$, la proyección de $\vec{a}$ sobre $\vec{b}$ viene dada por

$$\vec{a}_1 = \frac{\vec{a}^t \vec{b}}{||\vec{b}||}$$



El problema se traduce matemáticamente en:

$$\begin{aligned} &\max V[X\vec{v}] \\ &\text{sujeto a: } ||\vec{v}|| = 1 \end{aligned}$$

Desarrollando la varianza:

$$V \left[\frac{1}{d} (X\vec{v})^t X\vec{v} \right] = \frac{1}{d} \vec{v}^t X^t X \vec{v}$$

donde se ha asumido que el valor medio de los datos en cada una de las dimensiones es 0.

Por otro lado,

$$C_X = \frac{1}{d} X^t X$$

Finalmente, el problema queda

$$\begin{aligned} &\max \vec{v}^t C_X \vec{v} \\ &\text{sujeto a: } ||\vec{v}|| = 1 \end{aligned}$$

Se resuelve el problema de maximización sujeto a una condición de contorno:

$$\mathcal{L}(\vec{v}, \lambda) = \vec{v}^t C_X \vec{v} - \lambda (||\vec{v}|| - 1)$$

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial \vec{v}} = 0 \\ \frac{\partial \mathcal{L}}{\partial \lambda} = 0 \end{cases} \Leftrightarrow \begin{cases} C_X \vec{v} - \lambda \vec{v} = 0 \\ ||\vec{v}|| = 1 \end{cases}$$

Nótese que la primera ecuación del sistema de ecuaciones se puede escribir como:

$$C_X \vec{v} = \lambda \vec{v}$$

No se ha encontrado una solución pero sí una condición para la solución, la dirección que maximiza la varianza es un autovector de la matriz de covarianza.

Volviendo al sistema original:

$$\left. \begin{array}{l} \max V[X\vec{v}] \\ \text{sujeto a: } ||\vec{v}|| = 1 \end{array} \right\} \Leftrightarrow \left. \begin{array}{l} \max \vec{v}^t C_X \vec{v} \\ \text{sujeto a: } ||\vec{v}|| = 1 \end{array} \right\} \Leftrightarrow \left. \begin{array}{l} \max \vec{v}^t \lambda \vec{v} \\ \text{sujeto a: } ||\vec{v}|| = 1 \end{array} \right\} \Leftrightarrow \max \lambda$$

La dirección cuya proyección da la máxima varianza es aquella que coincide con la dirección del autovector asociado al mayor autovalor.

Por tanto, lo único que hay que hacer es calcular los autovalores de la matriz de covarianza y quedarse con aquel que tiene mayor valor.

Si se quieren más direcciones, se ve que éstas corresponden con las direcciones de los autovectores asociados a los autovalores en orden decreciente.

Sea X una variable aleatoria y sea $Y = aX$. Entonces, $V[Y] = a^2V[X]$.

Si se quiere sustraer del análisis que se acaba de hacer el efecto que tiene en la variabilidad de las distintas dimensiones el hecho de que tengan distintas escalas, entonces, hay que dividir cada dimensión (columna en los datos) por su desviación estándar.

Puesto que en el análisis se ha supuesto que los datos tienen media 0, entonces, hay que estandarizar los datos.

PROCEDIMIENTO

Sea una matriz de n datos de dimensión d : $X \in \mathbb{R}^{n \times d}$ (asumimos estandarizada)


Calcular la matriz de covarianza de los datos: $C_x = \frac{1}{n-1} X^t X$

Calcular los pares autovalor/autovector de la matriz de covarianza y ordenarlos de mayor a menor: $\{(\lambda_i, \vec{v}_i)\}_{i=1}^d$

Construir la matriz de autovectores: $P = \begin{pmatrix} | & | & & | \\ \vec{v}_1 & \vec{v}_2 & \dots & \vec{v}_d \\ | & | & & | \end{pmatrix}$

Proyectar los datos sobre los autovectores: $Y = XP$

Ejemplo: cálculo de las proyecciones principales de un conjunto de datos de dos dimensiones



La matriz de covarianza después de estandarizar los datos es:

$$C_X = \begin{pmatrix} 1 & 0.88 \\ 0.88 & 1 \end{pmatrix}$$

Autovalores/autovectores:



$$\lambda_1 = 1.88 \rightarrow \vec{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\lambda_2 = 0.12 \rightarrow \vec{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$

Matriz de cambio de base:

$$P = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$$

Proyecciones sobre los autovectores: $Y = XP$



El ejemplo resuelto a mano, usando numpy y usando sklearn se puede encontrar en la documentación del curso: [pca_ejemplo_clase.ipynb](#)

Varianzas de las variables proyectadas

Recordatorio: traza de una matriz tras un cambio de base

La traza (suma de los elementos de la diagonal) de una matriz es invariante bajo cambios de base.

Sean $\tilde{X} = PX$ donde $\tilde{X}$ es el conjunto de variables transformadas usando PCA y X es el conjunto de datos original (estandarizado). Entonces,

$$\text{tr}(C_{\tilde{X}}) = \text{tr}(C_X)$$

$$\sum_{i=1}^d \lambda_i = \sum_{i=1}^d V[X_i]$$

La suma de los autovalores (varianzas en el espacio transformado) es igual a la suma de las varianzas de cada una de las variables del espacio original.

Por tanto, la razón entre un autovalor y la traza de la matriz representa la cantidad de varianza del conjunto original que retiene la nueva variable:


$$\frac{\lambda_i}{\sum_{j=1}^d \lambda_j} \equiv \text{varianza retenida por la } i\text{-ésima componente principal}$$

Este resultado da indicaciones de cómo seleccionar el número de dimensiones del espacio reducido.

Selección del número de componentes principales


•Método del codo

Este es un método visual e intuitivo similar al aplicado para la selección de k en k-means. Se realiza un gráfico donde se muestra el valor de los autovalores (de mayor a menor), que no es más que la varianza explicada por cada una de las componentes principales. Cuando la curva se vuelve plana indica que al usar más componentes no se está explicando más varianza.



- **Varianza explicada acumulada**

Puesto que se puede calcular la fracción de varianza explicada por cada componente, se pueden mantener tantas componentes hasta que se alcance una suma de varianza explicada de corte. Este valor de corte suele ser entre 0.7 y 0.9.



- **Criterio de Kaiser**

Consiste en quedarse con aquellas componentes que tienen un autovalor superior a 1 ya que éstas contienen una varianza superior a cada una de las variables originales. Sin embargo, en ocasiones se ha usado con una varianza explicada inferior (hasta 0.7).

Ver pca_ejemplo2_clase.ipnb

Comprensión de las componentes principales

Nótese que la transformación del espacio original al de componentes principales viene dado por la proyección:

$$Y = XV$$

donde

$$Y = \begin{pmatrix} | & | & \cdots & | \\ y_1 & y_2 & \cdots & y_n \\ | & | & \cdots & | \end{pmatrix} \in \mathcal{M}_{n \times k}$$

matriz de observaciones en el espacio de componentes principales

$$X = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_n \\ | & | & \cdots & | \end{pmatrix} \in \mathcal{M}_{n \times d}$$

matriz de observaciones en el espacio original

$$V = \begin{pmatrix} | & | & \cdots & | \\ v_1 & v_2 & \cdots & v_k \\ | & | & \cdots & | \end{pmatrix} \in \mathcal{M}_{d \times k}$$

matriz formada por las primeras k componentes principales

Los datos transformados son una combinación lineal de los originales, pudiendo entender la relación que hay entre ambos:

$$Y = XV \rightarrow \vec{y}_i = X\vec{v}_i$$

Luego, si $(x_1, x_2, \dots, x_d)$ son las variables originales, entonces, las variables transformadas vienen dadas por:

$$y_i = \sum_{j=1}^d x_j v_{i,j}$$

donde v_{ij} es la coordenada j-ésima del autovector $\vec{v}_i$ (ver `pca_ejemplo2_clase.ipynb`)

Ventajas/desventajas de PCA

Ventajas

- Se pueden reducir las variables, por tanto, a la hora de entrenar un modelo para, por ejemplo, clasificación, se reducen los tiempos.
- El nuevo espacio está compuesto por variables independientes, con lo que se reduce la redundancia.
- Se queda con la mayor varianza, por tanto, deja fuera variables dominadas por el ruido (asumiendo que el efecto del ruido es menor que el de la variable).
- Si se reduce a 2D/3D ayuda a obtener visualizaciones que sean útiles en el análisis exploratorio de los datos.

Desventajas

- Asume relaciones lineales entre las variables, que no sucede siempre.
- Siempre se pierde información.
- Se asume que la varianza de las variables es lo que contiene la mayor información.
- No es útil para datos categóricos (hay versiones que sí, pero no esta).



www.unir.net